



3. JANUAR 2026

System zur Unterstützung der Diagnose und Stadieneinteilung von Lipödem, Lymphödem und Lipo-Lymphödem

BELIZ SENOL
HOCHSCHULE DÜSSELDORF

Abstrakt

Lymphödem und Lipödem sind chronische Erkrankungen, die zu Schwellungen und veränderten Körperproportionen führen. In dieser Arbeit stelle ich ein messdatenbasiertes Diagnosesystem vor, welches anhand standardisierter Umfangmessungen und Symptom-Scores vorhersagt, ob eine Person gesund ist oder an einem Lipödem/Lymphödem (Stadium 1–3) bzw. einem Lipo-Lymphödem leidet. Als Datenbasis dient ein anonymisierter Datensatz mit ca. 4.000 Fällen aus der Zusammenarbeit mit dem Startup Lymphdot und klinischen Partnern. Wir vergleichen drei Modellklassen (Support Vektor Machine, Random Forest, Multilayer Perzeptron) und kombinieren deren Ausgaben per Soft-Voting, um eine robustere Entscheidung zu erhalten. Das System ist in eine Online-Pipeline mit einheitlicher Vorverarbeitung, Plausibilitätschecks (OOD-Markierung) und grafischer Benutzeroberfläche integriert.

Inhaltsverzeichnis

Abstrakt	2
1.0 Einleitung.....	4
2.0 Daten	4
2.1 Herkunft und Anonymisierung.....	5
2.2 Zielvariable und Klassen	5
2.3 Features: Basisdaten, Umfangmessungen und Symptome	5
3.0 Programmaufbau	6
3.1 Offline (Training)	6
3.1.1 Datenvorbereitung	6
3.1.2 Training und Evaluation	7
3.2 Online (Inferenz)	8
3.2.1 Vorbereitung.....	8
3.2.2 Vorhersage und Ausgabe	8
4.0 Modelvergleich und Auswertung.....	10
5.0 Feature Reduktion	15
6.0 Fazit und Ausblick.....	18
6.0 Anhang.....	19
6.1 Medi Maßblatt Bein.....	19
6.2 Medi Maßblatt Arm	20
6.3 Quellenverzeichnis	21

1.0 Einleitung

Mein Ziel war es, ein Diagnosesystem für Lymphödeme und Lipödeme zu entwickeln. Das System soll anhand von Körpermesswerten vorhersagen, ob eine Person an einem dieser Krankheitsbilder leidet und in welchem Stadium sich die Erkrankung befindet.

Ein **Lymphödem** entsteht, wenn sich Flüssigkeit im Gewebe staut, weil das Lymphsystem nicht richtig arbeitet. Ein **Lipödem** ist dagegen eine Fettverteilungsstörung: Es bildet sich krankhaft vermehrtes Fettgewebe, meist an Beinen und/oder Armen. Beide Erkrankungen können sich unter anderem durch auffällige **Körperproportionen** zeigen, zum Beispiel wenn die Beine deutlich stärker betroffen sind als der Oberkörper. Für ein zuverlässiges Modell ist es deshalb wichtig, nicht nur „dick“ zu erkennen, sondern typische **Muster und Verhältnisse** zwischen verschiedenen Körperstellen zu berücksichtigen. So kann besser zwischen normaler Körperfülle und einer Erkrankung unterschieden werden. Sowohl Lymphödem als auch Lipödem werden üblicherweise in **drei Stadien** eingeteilt, die den Schweregrad beschreiben; treten beide Erkrankungen gleichzeitig auf, spricht man von einem **Lipo-Lymphödem**.

Das Projekt entsteht in Zusammenarbeit mit dem Startup **Lymphdot**, das mit Forschungszentren und Praxen kooperiert und dadurch Zugang zu anonymisierten Messdaten erhält. Lymphdot entwickelt eine Therapie, bei der das Erkrankungsstadium eine zentrale Rolle spielt. Das hier entwickelte Diagnosesystem soll diese Einschätzung unterstützen und die Einordnung in Stadien erleichtern. Dazu vergleichen wir drei etablierte Modelltypen (**SVM**, **Random Forest** und **MLP**), um zu untersuchen, welches Verfahren die Erkrankungen und ihre Stadien am zuverlässigsten unterscheiden kann.

2.0 Daten

Für ein Diagnosesystem wie dieses kommen grundsätzlich zwei Arten von Daten infrage: Bilddaten (z.B. Ganzkörperfotos) oder Messdaten (z.B. Umfangsmessungen). Gemeinsam mit Lymphdot haben wir beide Optionen abgewogen und uns bewusst für Messdaten entschieden.

Bilddaten hätten den Vorteil, dass sie schnell aufgenommen werden können und für Endnutzer:innen zunächst „einfach“ wirken. In der Praxis sind sie jedoch problematisch: Für eine zuverlässige Auswertung wäre meist ein Foto in sehr wenig Kleidung nötig, was sowohl bei der Datenerhebung in Praxen als auch beim späteren Einsatz zu Hemmungen und Datenschutzproblemen führen kann. Zusätzlich sind bildbasierte Modelle oft rechenintensiver und benötigen häufig mehr Trainingsdaten, um stabil zu lernen.

Messdaten sind dagegen deutlich weniger sensibel, weil sie keine direkt identifizierenden Bildinformationen enthalten. Außerdem eignen sie sich gut für verschiedene klassische Machine-Learning-Modelle (nicht nur neuronale Netze), was den Vergleich mehrerer Verfahren ermöglicht. Ein Nachteil ist der Aufwand: Umfangsmessungen müssen sorgfältig durchgeführt werden, und bei Selbstmessungen können Fehler entstehen (z.B. falsche Messhöhe oder zu stark/zu locker angelegtes Maßband). Für unser Projekt überwiegen dennoch die Vorteile, da solche Messungen in der medizinischen Versorgung ohnehin etabliert sind und gut standardisiert erhoben werden können.

2.1 Herkunft und Anonymisierung

Die Daten wurden im Rahmen der Zusammenarbeit mit dem Startup Lymphdot über Partnerpraxen und Forschungszentren erhoben und **anonymisiert** bereitgestellt. Der Datensatz enthält ca. **4.000** Einträge (jeweils eine Person). Es werden keine direkt personenbezogenen Identifikatoren verarbeitet (z.B. Name oder Kontaktinformationen), sondern ausschließlich medizinisch relevante Mess- und Basisdaten.

2.2 Zielvariable und Klassen

Jede Person besitzt genau eine Zielklasse, die die Diagnose und – falls zutreffend – das Stadium beschreibt. Vorhergesagt werden folgende Klassen:

- Gesund
- Lipödem Stadium 1
- Lipödem Stadium 2
- Lipödem Stadium 3
- Lymphödem Stadium 1
- Lymphödem Stadium 2
- Lymphödem Stadium 3
- Lipo-Lymphödem

Damit ist das Ziel nicht nur „krank vs. gesund“, sondern auch die feine Unterscheidung der Stadien, da diese in der Praxis entscheidend für Therapieplanung und Verlaufskontrolle sind.

2.3 Features: Basisdaten, Umfangmessungen und Symptome

Der Datensatz enthält zuerst Basisinformationen wie Gewicht, Grösse, Alter und Geschlecht. Den Hauptteil bilden Umfangmessungen an 28 Messpunkten des Körpers: mehrere Messstellen an Armen und Beinen sowie zusätzliche Messpunkte auf Brust- und Taillenhöhe. Die Messpunkte sind nach einem standardisierten Schema definiert (MEDI-Standard), damit Messungen zwischen unterschiedlichen Praxen möglichst vergleichbar bleiben.¹² Die Messpunkte sind:

- Arm links cC, Arm links cC1, Arm links cD, Arm links cE, Arm links cF, Arm links cG
- Arm rechts cC, Arm rechts cC1, Arm rechts cD, Arm rechts cE, Arm rechts cF, Arm rechts cG
- Über Brust, Unter Brust, Tallie cT, Hüfte cH
- Bein links cB1, Bein links cC, Bein links cD, Bein links cE, Bein links cF, Bein links cG
- Bein rechts cB1, Bein rechts cC, Bein rechts cD, Bein rechts cE, Bein rechts cF, Bein rechts cG

Wichtig ist dabei, dass nicht nur einzelne Umfänge relevant sind, sondern auch **Proportionen und Seitenunterschiede**. Besonders beim Lymphödem ist häufig eine **Asymmetrie** zwischen links und rechts sichtbar. Daher werden **beide Beine und beide Arme** gemessen. Außerdem spielen die Arme eine wichtige Rolle, weil sie je nach Erkrankung und Stadium erst später deutlich anschwellen

¹ Vgl Anhang 6.1 und 6.2

² (medi GmbH & Co. KG, kein Datum)

können. Diese Muster helfen dem Modell, Stadien innerhalb derselben Erkrankung besser zu unterscheiden.

Zusätzlich werden für jedes Bein fünf Symptome bzw. klinische Eindrücke auf einer Skala von 0 bis 10 erfasst (0 = nicht vorhanden, 10 = sehr stark):

- **Druckdelle (Pitting):** Wie stark bleibt eine Delle sichtbar, wenn man kurz auf die Stelle drückt? Eine deutliche Dellenbildung spricht oft für Flüssigkeitseinlagerung.
- **Taubheit:** Vermindertes Gefühl, Kribbeln oder „eingeschlafen“-Empfinden.
- **Schmerz:** Intensität von Schmerz im Alltag oder bei Berührung/Belastung.
- **Erwärmung:** Wärmegefühl an der Stelle (kann z.B. bei Reizung/Entzündung stärker sein).
- **Schwere/Trägheit:** Gefühl von schweren, müden oder „trägen“ Beinen.

Auch diese Angaben werden links und rechts getrennt erhoben, weil eine Asymmetrie (z.B. ein deutlich stärker betroffenes Bein) ein wichtiges Signal für die Klassifikation sein kann.

3.0 Programmaufbau

3.1 Offline (Training)

Das Training der Modelle erfolgt offline und wird je Modell über ein eigenes Skript gestartet (`train_svm.py`, `train_rf.py`, `train_nn.py`). Obwohl die Modelle getrennt trainiert werden, ist der Ablauf in allen Fällen sehr ähnlich: zuerst werden die Daten geladen und die verwendeten Features festgelegt, anschließend werden Trainings- und Testdaten erzeugt, die Daten werden vorverarbeitet und skaliert, und danach wird das jeweilige Modell trainiert und ausgewertet. Zum Schluss werden alle Artefakte gespeichert, sodass die Online-Inferenz später exakt dieselben Verarbeitungsschritte anwenden kann wie das Training.

3.1.1 Datenvorbereitung

Zunächst wird die CSV-Datei eingelesen und die Zielvariable festgelegt (standardmäßig die Spalte `„Klassifizierung“`). Danach wird über `feature.json` entschieden, welche Spalten als Eingabefeatures verwendet werden. Diese Datei enthält pro Feature ein Boolesches Flag und ermöglicht es, Messpunkte schnell ein- oder auszuschalten, ohne den Code ändern zu müssen. Falls `feature.json` noch nicht existiert, wird sie automatisch erzeugt; falls im Datensatz neue Spalten auftauchen, werden diese ergänzt. So bleibt die Feature-Auswahl konsistent und eignet sich gleichzeitig für spätere Ablations-Experimente.

Im nächsten Schritt werden die Daten in Trainings- und Testdaten aufgeteilt. Standardmäßig wird ein 80/20-Split verwendet, wobei die Aufteilung stratifiziert nach Klassen erfolgt, damit die Klassenverteilung in Training und Test vergleichbar bleibt. Zur Reproduzierbarkeit werden feste Seeds genutzt (Default `seed=42`). Beim neuronalen Netz wird zusätzlich der Torch-Seed gesetzt, um das Training möglichst deterministisch zu machen.

Anschließend werden die Klassenlabels in numerische Werte umgewandelt. Das Label-Encoding wird dabei nur auf den Trainingsdaten aufgebaut und anschließend auf Trainings- und Testlabels angewendet. Damit wird verhindert, dass Informationen aus dem Testset in das Training "hineinleaken". Zusätzlich stellt ein Check sicher, dass im Testset keine unbekannten Klassen auftauchen.

Danach folgt die zentrale Vorverarbeitung der Features. Zuerst wird das Geschlecht in eine numerische Darstellung umgewandelt. Zusätzlich werden die Eingabewerte pro Feature auf plausible Bereiche begrenzt: Aus den Trainingsdaten werden Grenzen über Trainings-Quantile bestimmt (z.B. 1%- und 99%-Quantil), und sowohl Trainings- als auch Testdaten werden auf diese Grenzen geclippt. Dieser Schritt reduziert den Einfluss von Ausreißern und Messfehlern, ohne harte manuell definierte Grenzwerte zu benötigen. Im Anschluss wird ein Preprocessor angewendet, der fehlende Werte imputiert und die Daten standardisiert. Kontinuierliche Merkmale werden dabei typischerweise über Median-Imputation und Standardisierung verarbeitet; binäre Merkmale werden über den häufigsten Wert imputiert.

3.1.2 Training und Evaluation

Auf Basis dieser vorbereiteten Daten wird anschließend das jeweilige Modell trainiert. Bei der **SVM** wird ein RBF-Kernel eingesetzt, da er nichtlineare Zusammenhänge zwischen den Messpunkten abbilden kann. Der **Random Forest** wird als Ensemble aus vielen Entscheidungsbäumen trainiert (Default 300 Bäume). Das **neuronale Netz (MLP)** wird epochen-basiert mit Mini-Batches optimiert. Es besteht aus mehreren voll verbundenen Schichten (mit Dropout als Regularisierung) und wird mit Cross-Entropy-Loss trainiert; als Optimierer verwenden wir AdamW, der zusätzlich Weight Decay nutzt und dadurch Überanpassung reduzieren kann.

Nach dem Training werden die Modelle auf dem Testset evaluiert. Neben Accuracy werden weitere Kennzahlen über einen `classification\_report` ausgegeben und eine Confusion Matrix erstellt, um typische Klassenverwechslungen sichtbar zu machen. Für eine anschauliche Darstellung werden außerdem PCA-Projektionen erzeugt: dazu zählen eine 2D-Visualisierung der Decision Regions im PCA-Raum, sowie eine 3D-PCA-Darstellung, teilweise ergänzt um eine Markierung, ob ein Sample korrekt oder falsch klassifiziert wurde. Beim neuronalen Netz wird zusätzlich eine Lernkurve über die Epochen (Train und Test Loss) gespeichert, während bei SVM und Random Forest der LogLoss auf Train und Test als kompakter Vergleich ausgegeben wird.

Zum Abschluss werden alle Artefakte gespeichert, die für die Online-Inferenz benötigt werden: Dazu gehören das trainierte Modell, der Preprocessor, die verwendete Feature-Reihenfolge, die Klassenliste sowie die Clipping-Grenzen pro Feature.

3.2 Online (Inferenz)

Für die Online-Nutzung gibt es eine GUI. Die dort eingegebenen Daten werden an `inference_main` übergeben, welches die drei modell-spezifischen Inferenzmodule (SVM, Random Forest und MLP) aufruft und deren Vorhersagewahrscheinlichkeiten berechnet. Anschließend sammelt `inference_main` diese Ergebnisse, kombiniert sie per Soft-Voting zu einer gemeinsamen Vorhersage und gibt das Resultat wieder über die GUI aus.

3.2.1 Vorbereitung

Daten eingeben

Es gibt drei mögliche Wege (je nach Nutzung über CLI oder GUI):

- **CSV-Datei (Batch-Inferenz):** Eine CSV mit allen Feature-Spalten (ohne Klassifizierung), mehrere Zeilen möglich; fehlende Werte sind erlaubt.
- **Interaktiver Modus (Terminal):** Werte werden nacheinander eingegeben; leere Eingaben werden als fehlende Werte behandelt.
- **Template-CSV:** Das Skript kann eine Vorlage mit allen benötigten Spalten erzeugen, die anschließend ausgefüllt und wieder eingelesen wird.

In der **GUI** werden praktisch die gleichen Eingabearten abgedeckt: Entweder wird eine CSV ausgewählt oder die Werte werden manuell in Eingabefelder eingetragen.

Artefakte laden

Beim Start lädt das jeweilige Skript automatisch folgende gespeicherte Artefakte:

- das trainierte Modell (SVM, RF, MLP),
- den **Preprocessor** Imputation + Skalierung + Feature-Reihenfolge),
- sowie **Meta-Informationen** (Klassenliste und Grenzen pro Feature).

Data Prepare

Vor der Vorhersage werden die Eingaben robust vorbereitet:

- **Spaltenabgleich:** fehlende Spalten werden ergänzt (z.B. NaN) und die Reihenfolge an das Training angepasst.
- **Normalisierung Geschlecht:** verschiedene Schreibweisen werden konsistent gemappt.
- **Clipping auf Trainings-Quantile:** Werte werden pro Feature auf plausible Bereiche begrenzt.
- **Transformation:** Anwendung des gespeicherten Preprocessors (Imputation + Skalierung) – identisch zum Training.

3.2.2 Vorhersage und Ausgabe

Nachdem die Daten vorbereitet wurden, berechnet jedes Modell für jede Person eine Wahrscheinlichkeitsverteilung über alle Klassen (z.B. „gesund“, „Lipödem Stadium 2“, ...). Wir erhalten eine Verteilung (statt nur einer Klasse), weil das Modell für jede mögliche Klasse einen internen Score berechnet und dieser anschließend in Wahrscheinlichkeiten umgerechnet wird. Dadurch sieht man nicht nur die beste Klasse, sondern auch, ob das Modell zwischen mehreren Klassen unsicher ist (z.B. Stadium 1 vs. Stadium 2). Diese Wahrscheinlichkeiten werden später auch für die Top-3-Ausgabe genutzt. Das Berechnen dieser Verteilung passiert je nach Modell unterschiedlich:

SVM:

Eine SVM berechnet zunächst Roh-Scores (decision function), die vereinfacht sagen, wie weit ein Punkt von der Entscheidungsgrenze entfernt ist. Diese Werte sind noch keine Wahrscheinlichkeiten, weil sie nicht auf $[0,1]$ begrenzt sind und nicht direkt „60% sicher“ bedeuten. In unserem Setup werden diese Scores nach dem Training kalibriert (typisch über *Platt Scaling*, also eine logistische Abbildung), sodass daraus Wahrscheinlichkeiten entstehen. Bei mehreren Klassen werden die einzelnen binären/paarweise Ergebnisse anschließend zu einer gemeinsamen Wahrscheinlichkeitsverteilung kombiniert.

Random-Forest:

Ein Random Forest besteht aus vielen Entscheidungsbäumen, die jeweils eine Klasse vorhersagen. Die „Wahrscheinlichkeit“ pro Klasse entsteht aus dem Anteil der Bäume, die für diese Klasse stimmen (bzw. aus gemittelten Klassenhäufigkeiten in den Blättern). Das ist meist gut nutzbar, entspricht aber nicht zwingend einer perfekt kalibrierten statistischen Wahrscheinlichkeit.

MLP:

Ein MLP gibt am Ende pro Klasse einen Score (Logit) aus. Mit der Softmax-Funktion werden diese Logits in eine Verteilung umgerechnet: alle Werte liegen zwischen 0 und 1 und summieren sich zu 1. In der Praxis können Softmax-Werte manchmal overconfident sein (z.B. sehr hohe Wahrscheinlichkeiten, obwohl ein Fall schwierig ist). Um dem entgegen zu wirken und die Verteilung etwas zu glätten, wird bei der Inferenz eine Temperatur t genutzt:

$$\text{Softmax}(z) = \frac{e^{\frac{z_i}{t}}}{\sum e^{\frac{z_i}{t}}}$$

Ausgabe

Bei der Ausgabe wird mithilfe einer **Out-of-Distribution-Markierung (OOD)** überprüft, ob eine Eingabe deutlich außerhalb dessen liegt, was im Training typisch war. Das ist kein Fehler und kein Abbruch, sondern ein Warnhinweis („Eingabe ungewöhnlich → Vorhersage mit Vorsicht interpretieren“). Die OOD-Prüfung basiert auf den standardisierten Feature-Werten: durch die Standardisierung wird jeder Messwert so umgerechnet, dass er beschreibt, wie stark er vom typischen Trainingswert abweicht. Ein Wert nahe 0 ist sehr typisch; größere Beträge bedeuten, dass der Messwert im Training deutlich seltener vorkam. Für jedes Sample wird anschließend ein einziger OOD-Score berechnet, indem der größte Betrag über alle standardisierten Feature-Werte genommen wird (also der extremste Ausreißer innerhalb dieses Samples). Überschreitet dieser Wert den Schwellwert OOD-threshold, wird das gesamte Sample als OOD markiert. Das kann zum Beispiel passieren, wenn einzelne Eingaben oder Kombinationen von Eingaben stark untypisch sind. Auch wenn extremes Verhalten durch Clipping begrenzt wird, kann ein Fall im standardisierten Raum weiterhin deutlich außerhalb des „Gelernten“ liegen.

Am Ende werden die drei Modellvorhersagen in `inference_main` zu einer gemeinsamen Entscheidung zusammengeführt. Dafür wird **Soft-Voting** verwendet: Jedes Modell liefert eine Wahrscheinlichkeitsverteilung über alle Klassen (z.B. `predict_proba` bzw. `Softmax`). Diese Wahrscheinlichkeiten werden klassenweise gemittelt, sodass für jede Klasse eine gemittelte Wahrscheinlichkeit entsteht. Die finale Vorhersage ist anschließend die Klasse mit der höchsten gemittelten Wahrscheinlichkeit. Durch dieses Vorgehen wird die Ausgabe in vielen Fällen stabiler, weil sich die Stärken der Modelle ergänzen und einzelne „Ausreißer“-Vorhersagen weniger stark ins Gewicht fallen.

4.0 Modelvergleich und Auswertung

Das Diagramm vergleicht Precision, Recall und F1-Score der drei Modelle (NN, SVM, RF). Insgesamt zeigt sich, dass die **SVM** in allen Kennzahlen die beste Leistung erreicht (Precision $\approx 0,9828$; Recall $\approx 0,9825$; F1 $\approx 0,9825$). Das **neuronale Netz** liegt nur knapp darunter (Precision $\approx 0,9806$; Recall/F1 $\approx 0,98$), der Abstand zur SVM ist also gering, aber über alle Metriken hinweg konsistent. Der **Random Forest** schneidet im Vergleich deutlich schwächer ab (Precision $\approx 0,972$; Recall $\approx 0,9712$; F1 $\approx 0,9711$) und bleibt damit rund 0,01–0,012 Punkte hinter den beiden anderen Verfahren. Auffällig ist außerdem, dass bei allen Modellen Precision, Recall und F1-Score sehr nah beieinanderliegen. Das deutet darauf hin, dass die Modelle ein insgesamt ausgewogenes Fehlverhalten besitzen und nicht etwa stark in Richtung „zu viele False Positives“ oder „zu viele False Negatives“ kippen. Da die globalen Werte insgesamt sehr hoch sind (alle über 0,97), ist für die weitere Interpretation vor allem interessant, welche Klassen die verbleibenden Fehler verursachen – typischerweise sind dies Verwechslungen zwischen benachbarten Stadien, da diese sich in den Messwerten am stärksten ähneln (Vgl. Abb. 1).




Abb. 1

Die Loss-Kurven des neuronalen Netzes zeigen einen typischen Trainingsverlauf mit schneller Konvergenz und anschließend leichtem Auseinanderlaufen von Train- und Test-Loss. In den ersten Epochen fällt der Train-Loss sehr stark (von ca. 1,2 auf unter 0,2), und auch der Test-Loss sinkt parallel (von ca. 0,6 auf etwa 0,15). Das deutet darauf hin, dass das Modell die grundlegenden Muster in den Daten sehr schnell lernt. Ab etwa Epoche 8–15 flacht die Verbesserung deutlich ab. Der Train-Loss sinkt weiter kontinuierlich Richtung nahezu 0, während der Test-Loss nur noch langsam besser wird und anschließend leicht schwankt. Dieses Muster spricht für beginnendes Overfitting: das Modell passt sich zunehmend an die Trainingsdaten an, ohne dass sich die Generalisierung auf dem Testset im gleichen Maß verbessert. Dennoch bleibt der Test-Loss insgesamt auf einem sehr niedrigen Niveau, was zur hohen Klassifikationsleistung passt.

Zur Modellselektion wird während des Trainings die Epoche mit dem **niedrigsten Test-Loss** verfolgt und am Ende der Trainingslauf auf genau diesen Checkpoint zurückgesetzt. In diesem Experiment liegt das Optimum bei **Epoche 43** mit einem Test-Loss von **0,0414**. Dadurch wird verhindert, dass ein späterer Checkpoint mit bereits wieder leicht verschlechterter Testleistung für die finale Auswertung verwendet wird. Entsprechend beziehen sich auch die im Test-Report berichteten Kennzahlen (Precision, Recall, F1-Score usw.) auf das **zurückgesetzte Modell aus Epoche 43** und nicht auf die allerletzte Trainings-Epoche.

Insgesamt zeigt die Kurve, dass das Neuronale Netz sehr schnell ein stabiles Leistungsniveau erreicht und dass die Auswahl des besten Test-Checkpoints hilft, mögliche Overfitting-Effekte in späteren Epochen zu begrenzen (Vgl. Abb. 2)




Abb. 2

Der SVM-Klassifikator erreicht auf dem Test-Set eine sehr hohe Accuracy von **0,9825** bei einem Test-LogLoss von **0,0744** (Train: **0,0512**). Der Abstand zwischen Train- und Test-LogLoss bleibt somit vergleichsweise klein, was darauf hindeutet, dass das Modell seine Leistung nicht nur „auswendig gelernt“ hat, sondern auch auf bisher ungesehenen Daten stabil bleibt. Da der LogLoss nicht nur die richtige Klasse bewertet, sondern auch die Qualität der Wahrscheinlichkeiten (hohe Strafe für „sehr sicher, aber falsch“), spricht der niedrige Test-LogLoss für eine insgesamt konsistente und brauchbare probabilistische Ausgabe, die sich auch für Top-k-Ausgaben oder ein späteres Soft-Voting eignen.

Im Vergleich dazu zeigt der Random Forest deutlich höhere Loss-Werte. Während der RF beim Train-LogLoss noch in einem ähnlichen Bereich liegt (ca. **0,067**), steigt der Test-Loss stark an (ca. **0,205**).

Diese Differenz weist auf eine schwächere Generalisierung bzw. weniger zuverlässige Wahrscheinlichkeiten hin: Der RF ist bei den Trainingsdaten relativ sicher, aber auf dem Testset werden falsche Vorhersagen offenbar häufiger mit zu hoher Sicherheit getroffen, welches den LogLoss stark erhöht. Das passt auch zur insgesamt schlechteren Performance des RF in Precision/Recall/F1.

Insgesamt stützt der Loss-Vergleich somit die Beobachtung aus den Metriken: SVM liefert die stabilsten und am besten generalisierenden Ergebnisse und ist gleichzeitig die bessere Basis für probabilistische Ausgaben (Top-3) und Ensemble-Verfahren. Für eine genauere Fehleranalyse wäre als nächster Schritt sinnvoll zu prüfen, welche Klassen den Test-Loss beim RF treiben (z.B. durch Confusion-Matrix und per-Klasse-LogLoss), da besonders Verwechslungen zwischen benachbarten Stadien typischerweise die höchsten Unsicherheiten verursachen (Vgl. Abb. 3)




Abb. 3

In den normalisierten Confusion Matrixen fällt vor allem auf, dass Fehlklassifikationen nicht zufällig auftreten, sondern fast immer zwischen medizinisch nahen Klassen liegen. Besonders häufig werden benachbarte Stadien innerhalb derselben Erkrankung verwechselt – also Stadium 1 ↔ 2 oder 2 ↔ 3. Das ist plausibel, weil die Übergänge zwischen Stadien fließend sind und sich die Messwerte in diesen Grenzbereichen stark ähneln.

Am deutlichsten zeigt sich dieses Muster bei Lymphödem Stadium 2. Diese Klasse wird in allen drei Modellen am häufigsten mit Lymphödem Stadium 1 verwechselt: Bei der SVM gehen ca. **6%** der Stadium-2-Fälle in Stadium 1 über, beim **RF** sogar ca. **7%**. Verwechslungen in Richtung Stadium 3

treten seltener auf (bei der SVM etwa **2%**). Insgesamt ist Stadium 2 damit als „Zwischenklasse“ am schwierigsten abzugrenzen, während Stadium 1 und Stadium 3 deutlich stabiler erkannt werden.

Ein zweiter auffälliger Bereich betrifft Lipödem Stadium 2, insbesondere beim Random Forest. Dort liegt der Recall für diese Klasse nur bei **0,91**, und die Fehler verteilen sich vor allem auf Lipödem Stadium 1 (**≈0,03**) und Lipödem Stadium 3 (**≈0,05**). Das zeigt, dass der RF bei mittleren Lipödem-Fällen stärker zwischen „noch eher mild“ und „schon eher schwer“ schwankt. Beim NN und bei der SVM ist Lipödem Stadium 2 dagegen deutlich stabiler (nur geringe Verwechslungen zu den Nachbarstadien).

Beim Lipo-Lymphödem sind Fehlzugeordnungen insgesamt selten, aber wenn sie vorkommen, gehen sie meist in Richtung Lipödem Stadium 3 (kleiner Anteil, etwa **1–2%**). Auch das ist inhaltlich nachvollziehbar, da Lipo-Lymphödem häufig stark ausgeprägte Merkmale zeigt und dadurch dem schweren Lipödem ähneln kann.

Zusammenfassend konzentrieren sich die wichtigsten Fehlerquellen auf die Stadiengrenzen, insbesondere bei Stadium 2. Für weitere Verbesserungen wäre es daher sinnvoll, genau diese Grenzfälle gezielt zu analysieren (z.B. welche Features bei Stadium-2-Patient:innen am stärksten mit Stadium 1/3 überlappen) oder zusätzliche Merkmale einzubeziehen, die den Übergang zwischen den Stadien besser abbilden. (Vgl. Abb. 4-6)




Abb. 4: NN - Confusion matrix




Abb. 5: SVM- Confusion matrix




Abb. 6: RF- Confusion matrix

Die drei Abbildungen 7 bis 9 zeigen sogenannte Correctness-Plots im PCA-Raum (PC1–PC3). Jeder Punkt entspricht einem Test-Sample; grün bedeutet korrekt klassifiziert, rot bedeutet Fehlklassifikation. Die Klassen selbst werden hier absichtlich nicht dargestellt, da es nur um einen schnellen Überblick über die Verteilung und Häufung von Fehlern geht.

In allen drei Plots liegen die roten Punkte überwiegend in Bereichen, in denen die Punktwolke dichter und stärker überlappt. Das deutet darauf hin, dass Fehlklassifikationen vor allem bei Fällen auftreten, die im Merkmalsraum sehr ähnlich sind – typischerweise Grenzfälle zwischen nahen Stadien. Im direkten Vergleich zeigt der Random Forest sichtbar mehr rote Punkte als die beiden anderen Modelle, während beim NN die wenigsten Fehlpunkte auftreten; die SVM liegt dazwischen. Insgesamt dominieren aber in allen Abbildungen klar die grünen Punkte, was die hohe Gesamtgenauigkeit aller drei Modelle zusätzlich bestätigt.




Abb. 7: SVM - richtig und falsch klassifizierte Daten




Abb. 8: RF - richtig und falsch klassifizierte Daten




Abb. 9: NN - richtig und falsch klassifizierte Daten

Zusammenfassend ergibt der Vergleich, dass **SVM und NN** sehr ähnlich stark performen und sowohl in den globalen Metriken (Precision/Recall/F1 $\approx 0,98$) als auch in den Confusion Matritzen eine sehr stabile Trennung erreichen. Die verbleibenden Fehler konzentrieren sich bei beiden – wie zu erwarten – auf **Grenzfälle zwischen benachbarten Stadien**, insbesondere bei **Stadium-2-Klassen** z.B. Lymphödem Stadium 2 $\leftrightarrow$ Stadium 1/3). Der **Random Forest** ist dagegen insgesamt schwächer (F1 $\approx 0,971$) und zeigt zudem genau in diesen ohnehin schwierigen Bereichen die größten Probleme. Damit ergänzt der RF die anderen Modelle nicht sinnvoll, weil er nicht dort stark ist, wo SVM/NN schwächer sind, sondern die gleichen Problemfälle eher verstärkt.

5.0 Feature Reduktion

Bei der Feature-Ablation wird untersucht, welche Messwerte für die Vorhersage wirklich notwendig sind und welche ausgelassen werden können, um die Dateneingabe für Endnutzer zu vereinfachen. Ziel ist daher, eine kleinere, aber weiterhin aussagekräftige Feature-Menge zu finden, die eine zuverlässige Diagnose- und Stadien Klassifikation ermöglicht. Dabei werden zwei Schritte unterschieden: Single-Feature-Ablation und Gruppen-Feature-Ablation. Ausgangspunkt ist jeweils eine Konfiguration, in der alle Features aktiv sind.

In der Single-Feature-Ablation wird anschließend in separaten Läufen jeweils genau ein Feature deaktiviert, während alle anderen unverändert bleiben. Für jeden Lauf werden die Modelle (SVM, RF, MLP/NN) mit identischem Split und identischem Seed trainiert und auf dem Testset bewertet. Als Vergleichsmaß wird der Macro-F1-Score verwendet. Ein starker Leistungsabfall beim Entfernen eines Features spricht dafür, dass dieses Feature wichtig ist; bleibt die Leistung nahezu unverändert, ist es ein Kandidat zum Weglassen.

Die Ergebnisse der Single-Feature-Ablation (Abbildung 10) zeigen zunächst, dass Hüfte und Taille mit einem identischen F1-Score von 0,982 den geringsten Einfluss auf die Gesamtleistung haben. Ebenfalls im gleichen Bereich liegt der Messpunkt „über Brust“ (F1 $\approx 0,981$), was darauf hindeutet, dass diese Rumpfmäße für die aktuelle Klassifikationsaufgabe weniger entscheidend sind als andere Messbereiche.

Sowohl am linken als auch am rechten Arm scheinen die Punkte cG und cC weniger entscheidend zu sein, da der F1-Score beim Entfernen dieser Features weiterhin bei $\geq 0,980$ liegt. Dies sind die Messpunkte ganz oben und ganz unten am Arm. Deutlich stärker wirkt sich dagegen das Entfernen von Bein-Messpunkten aus: sobald ein Bein-Feature fehlt, liegt der F1-Score durchgehend bei $\leq 0,980$. Das spricht dafür, dass die Beinmessungen eine zentrale Rolle spielen, insbesondere weil viele typische Muster von Lip- und Lymphödemen dort am stärksten ausgeprägt sind und zusätzlich Asymmetrien (links vs. rechts) wichtige Hinweise liefern können.

Überraschend ist außerdem, dass Größe und Geschlecht ebenfalls einen geringeren Einfluss haben als zunächst erwartet (F1 typischerweise zwischen 0,980 und 0,981).




Abb. 10: F1-Score nach Entfernung des jeweiligen Features aus den Trainingsdaten

Im zweiten Schritt wurde eine Gruppen-Feature-Ablation durchgeführt. Auf Basis der Ergebnisse der Single-Feature-Ablation wurden Features, die einzeln nur einen geringen Einfluss zeigten, zu sinnvollen Gruppen zusammengefasst. Anschließend wurden die drei Modelle jeweils mit deaktivierten Gruppen sowie mit Kombinationen mehrerer Gruppen getestet. Die Gruppen wurden wie folgt definiert:

- Gruppe 1: Hüfte, Taille, Über Brust
- Gruppe 2: die ausgewählte Arm-Messwerte
- Gruppe 3: Geschlecht und Größe

Die Ergebnisse in Abbildung 11 zeigen, dass in vielen Fällen durch das Entfernen einzelner Gruppen sogar leicht bessere F1-Scores erreicht werden als in der Ausgangskonfiguration („all features on“). Diese Verbesserungen sind jedoch sehr klein und lassen sich durch mehrere Effekte erklären: Erstens können schwach informative oder verrauschte Merkmale die Modelle leicht stören, sodass deren Entfernung zu einer minimal stabileren Entscheidung führt. Zweitens wirkt eine reduzierte Feature-Anzahl wie eine zusätzliche Regularisierung, da der Modellraum kleiner wird und Überanpassung geringfügig abnimmt. Drittens treten selbst bei fixem Split und Seed kleine Schwankungen auf (z.B. durch Stochastik im NN-Training). Schließlich reagiert der Macro-F1 besonders empfindlich, da bereits kleine Änderungen in einzelnen Klassen den Gesamtwert messbar verschieben können.

Nach Abwägung der Ergebnisse wurde entschieden, Gruppe 1 und Gruppe 2 zu entfernen. Damit steigt der F1-Score auf 0,9816, verglichen mit 0,9791 in der Ausgangskonfiguration mit allen Features. Dieses Resultat zeigt, dass sich insgesamt 7 Features ohne messbaren Qualitätsverlust (und in diesem Setup sogar mit leichtem Gewinn) entfernen lassen. Gruppe 3 wurde hingegen nicht entfernt, da Größe und Geschlecht in der Lymphdot-Software ohnehin bereits beim Anlegen eines Profils erfasst werden. Diese Informationen stehen also bereits zur Verfügung, sodass ihre Nutzung im Modell keinen zusätzlichen Messaufwand verursacht.




Abb. 11: Einfluss von Feature-Gruppen auf den Macro-F1-Score

Insgesamt reduziert die Feature-Reduktion den Eingabeumfang von 42 auf 35 Features. Dadurch wird das System benutzerfreundlicher, da weniger Messpunkte erhoben werden müssen, während die Modellleistung mindestens erhalten bleibt.

6.0 Fazit und Ausblick

In diesem Projekt wurde ein messdatenbasiertes Diagnosesystem entwickelt, das zwischen gesund, Lipödem Stadium 1–3, Lymphödem Stadium 1–3 und Lipo-Lymphödem unterscheidet. Auf dem anonymisierten Datensatz mit ca. 4.000 Fällen zeigen die Ergebnisse, dass die Klassifikation auf Basis standardisierter Umfangmessungen und Symptom-Scores sehr gut funktioniert. Besonders die SVM und das neuronale Netz erreichen durchgehend hohe Werte (Precision/Recall/F1 jeweils etwa im Bereich 0,98) und zeigen in den Confusion Matritzen nur wenige Fehlklassifikationen. Die verbleibenden Fehler treten vor allem dort auf, wo es fachlich plausibel ist: bei Grenzfällen zwischen benachbarten Stadien, insbesondere bei Stadium-2-Klassen. Der Random Forest ist insgesamt schwächer und zeigt seine größten Fehler genau in diesen Bereichen, wodurch er keinen klaren Ausgleich zu SVM und NN liefert.

Ein weiterer wichtiger Beitrag des Projekts ist die Dimensionsreduzierung durch Feature-Ablation. Sowohl die Single-Feature- als auch die Gruppen-Ablation zeigen, dass bestimmte Messpunkte nur einen geringen Einfluss auf die Modellleistung haben. Durch das Entfernen von 7 Features (Reduktion von 42 auf 35) konnte die Modellleistung mindestens gehalten und in der besten Kombination sogar leicht verbessert werden (Macro-F1 0,9816 gegenüber 0,9791 mit allen Features). Dies ist besonders relevant für den späteren Einsatz, da weniger Messpunkte den Aufwand reduziert und die Dateneingabe für Endnutzer deutlich einfacher macht.

Als nächster Schritt ist eine gezielte Analyse der Grenzfälle sinnvoll, um die häufigsten Verwechslungen (z.B. Stadium 1 $\leftrightarrow$ 2) besser zu trennen. Dazu bietet sich eine vertiefte Untersuchung an, welche Features die Klassifikation dieser Übergangsbereiche besonders beeinflussen, und ob zusätzliche, Stadien-spezifische Merkmale (z.B. Asymmetrie-Indikatoren oder neue klinische Scores) die Trennbarkeit verbessern. Zusätzlich wäre eine Optimierung des Random-Forest-Modells ein möglicher nächster Schritt. Falls sich die Fehler dadurch nicht ausreichend reduzieren lassen, wäre es konsequent, den Random Forest dauerhaft aus dem Soft-Voting herauszunehmen oder seinen Einfluss im Ensemble zu verringern (z.B. durch geringere Gewichtung).

6.0 Anhang

6.1 Medi Maßblatt Bein

circaid® Bestellblatt
Telefon: +49 921 912-950, Telefax: +49 921 912-955,
E-Mail: auftragsservice@medi.de




medi Kundennummer Versandanschrift Datum

Kommission (Nachname, Vorname)

☐ Bestellung
☐ Kostenvoranschlag

medi GmbH & Co. KG
Medicusstraße 1
95448 Bayreuth
Germany
T +49 921 912-950
F +49 921 912-955
auftragsservice@medi.de
www.medi.de

Absender / Stempel



circaid juxtalite	Stück	Größe						
circaid juxtalite		S	M	M – X	L	L – X	XL	XL – X
circaid juxtalite Fußteil		S	M					

Länge	
kurz	lang

circaid juxtafit essentials		Stück	Größe								Länge			
circaid juxtafit essentials Unterschenkel			S	M	M-X	L	L-X	XL	XL-X	XXL	XXXL	kurz	lang	
circaid juxtafit essentials	links		XXS	XS	S	M	L	XL				extra kurz	kurz	lang
Oberschenkel mit Knie	rechts		XXS	XS	S	M	L	XL				extra kurz	kurz	lang
circaid juxtafit premium interlocking Fußteil			S	M	L									

Zubehör	Stück	Größe		Variante		Ausführung	
circaid kompressive Socke		S	L				
circaid pac band Fußteil		S	L	XL			
circaid Unterziehstrumpf offen				Unterschenkel	Bein		
circaid Unterziehstrumpf offen silber				Unterschenkel			
circaid Unterziehstrumpf mit Fuß				Unterschenkel			
circaid Unterziehstrumpf silber mit Fuß				Unterschenkel			
circaid Überzug		S	L	Unterschenkel		beige	schwarz

Hinweis
circaid juxtafit Arm finden Sie auf der Rückseite

medi. ich fühl mich besser.

0050549 / 04.2024

6.2 Medi Maßblatt Arm

☐ Kostenvoranschlag ☐ Bestellung

☐ Lymphologie
☐ Narbenversorgung

Mailbestellung an medi • lymphservice@medi.de
Faxbestellung an medi • Telefax 0921 912-540

medi

Fachhandel (FH) _____

Kundenr. / VA _____ Ansprechpartner (FH) _____
(bitte immer angeben)

Kommission _____

Stempel /
Unterschrift _____

Liefertermin (im Haus) _____ Bestelldatum _____

5 4 3 2 1
Längenmaß ℓ_{XZ} ℓ_{XZ} ℓ_{XZ} ℓ_{XZ} ℓ_{XZ}
Umfangsmaß c_Z c_Z c_Z c_Z c_Z
Umfangsmaß c_X c_X c_X c_X c_X

HANDTEIL –
Umfangsmaße C
und Längenmaße ℓ

Hautmaß Zugmaß
cA cB cC cC1 cD cE

ℓ_{AB} ℓ_{AC} ℓ_{AC1} ℓ_{AD} ℓ_{AE}

ARMSTRUMPF –
Umfangsmaße C
und Längenmaße ℓ

Hautmaß Zugmaß
cG cF cE cD cC1 cC

ℓ_{GH} ℓ_{CG} ℓ_{CF} ℓ_{CE} ℓ_{CD} ℓ_{CC1}

Qualität	Kompression CCL 1 2 3	Standardfarben	Trendfarben*	Menge	Seite
☐ mediven	Handteil ☐ ☐ ☐	☐ Sand ☐ Cashmere	☐ Flieder ☐ Lichtblau	Stück _____	☐ links
☐ mondi esprit	Armstrumpf ☐ ☐ ☐	☐ Caramel ☐ Marine	☐ Salbeigrün ☐ Rostrot		☐ rechts
☐ mediven		☐ Schwarz ☐ Anthrazit			☐ Finger offen
550 Arm		☐ Grau* ☐ medi Magenta*			☐ Finger geschlossen

Varianten	Stand. Abschluss (proximal)	Variabler Abschluss
Handteil		
☐ AC1	gerade (porös)	☐ steile Schräge ☐ flache Schräge
☐ AD / AE	flache Schräge	☐ steile Schräge ☐ gerade
Armteil		
☐ CD / CE / CF / CG	flache Schräge	☐ steile Schräge ☐ gerade
☐ AF / AG (1-teilig)	flache Schräge	☐ steile Schräge ☐ gerade

Befestigung

Noppen-Haftband ☐ schmal 2,5 cm ☐ breit 5 cm
☐ Noppen-Haftband mit Motiv (5 cm)
☐ Mikronoppen-Haftband sensitiv (5 cm)
☐ Flächen-Haftband Rose (5 cm)

☐ Schulterkappe (Standard)
☐ Schulterkappe anatomisch _____ cm
☐ mit Schultergurt K Gurtbreite: ☐ 2,5 cm ☐ 5 cm
☐ mit BH-Befestigung Breite des BH-Trägers: _____ cm

Zusätze

Einkehren im Ellenbogenbereich 160° (Standard) ☐ 150° ☐ 135°
☐ Ellenbogen-Funktionszone (nur mediven 550)

Sonstige Zusätze

Position	Haftbandstück	Anti-Rutsch-Noppen
entlang Schräge	☐ 5 x 2,5 cm ☐ 5 x 5 cm ☐ 10 x 5 cm	☐ 6 x 4,5 cm
Handinnenfläche	☐ 5 x 5 cm	☐ 6 x 4,5 cm

_____ cm porös bei Handteil (proximal – Standard 2 cm)
 _____ cm porös bei Armstrumpf (distal – Standard 2 cm)

☐ Lymphpad ☐ Futterstoff ☐ Tasche
 Bitte genauen Bereich angeben / anzeichnen (Länge / Breite)

Muster** ☐ Design-Element ☐ Fashion-Element
☐ Bloom ☐ Nature ☐ Wild ☐ Stripes

nach letzter Maßnummer: _____

Sonderwunsch

* Lieferzeit bis zu 10 Arbeitstage; ** Für alle Standard- und Trendfarben möglich!

00265026 / 07.2024

mediven® Kompressionsversorgungen flachgestrickt mit Naht

6.3 Quellenverzeichnis

medi GmbH & Co. KG. (kein Datum). *medi*. Abgerufen am oktober 2025 von <https://www.medi.de/fachhandel/wissen/produktwissen/phlebologie-lymphologie/vorlagen-vermessung/>